StatistikEksamen2020

Statistik

Eksamensæt 2020

Opgave 1 – Byen med det første dødsfald i Italien

a.

Det antages, at det er lige sandsynligt for alle indbyggere at blive smittet, hvilket betyder at sandsynlighederne kan findes som antallet af smittet for hver hændelse (C) delt med antallet af indbyggere (U). Beregnes dette bliver sandsynligheden for de forskellige hændelser:

```
U = 3300
C1 = 89
C2 = 6
C3 = 0
PC1 = C1 / U
PC2 = C2 / U
PC3 = C3 / U

cat("P(C1) =", PC1, "\nP(C2) =", PC2, "\nP(C3) =", PC3)
```

```
## P(C1) = 0.0269697
## P(C2) = 0.001818182
## P(C3) = 0
```

b.

Da alle, der blev syge d. 20. marts, også blev syge d. 6. marts, vil det gælde at $P(C_2) = P(C_2 \cap C_1)$. Den betingede sandsynlighed kan findes som sandsyngligheden for fælleshændelsen delt med sandsynligheden for C_1. Den betingede sandsynlighed bliver da:

```
PC2nC1 = PC2
PC2lC1 = PC2nC1 / PC1
cat("P(C2 | C1) =", PC2lC1)
```

```
## P(C2 | C1) = 0.06741573
```

c.

Gider ikke skrive forklaring nu

```
S1nC1 = 89 - 63
PS1nC1 = S1nC1 / U
PS1lC1 = PS1nC1 / PC1

S1barnC1 = 63
PS1barnC1 = S1barnC1 / U
PS1barlC1 = PS1nC1 / PC1
```

```r
PC1bar = 1 - PC1
S1nC1bar = 127
PS1nC1bar = S1nC1bar / U
PS1lC1bar = PS1nC1bar / PC1bar

cat("P(S1 | C1) =", PS1lC1, "\nP(S1bar | C1) =", PS1barlC1, "\nP(S1 | C1bar) =", PS1lC1bar)
```

```
## P(S1 | C1) = 0.2921348
## P(S1bar | C1) = 0.2921348
## P(S1 | C1bar) = 0.03955154
```

d.

S_1 er antallet af folk, som udviser symptomer, hvilket må svare til alle dem dem med Corona fratrukket dem som ikke udviser symptomer ($S_1 \cap C_1$), adderet med alle dem som udviser symptomer, men ikke har Corona ($S_1 \cap \bar{C_1}$). Da det stadig antages at alle udfald i U er lige sandsynlige, kan $P(S_1)$ beregnes som $\frac{S_1}{U}$. Dette vil resultere i:

```r
S1 = 89 - 63 + 127
PS1 = S1 / U

cat("P(S1) =", PS1)
```

```
## P(S1) = 0.04636364
```

e.

Gider ikke skrive forklaring nu

```r
PC1lS1 = PS1nC1 / PS1
cat("P(C1 | S1) =", PC1lS1)
```

```
## P(C1 | S1) = 0.1699346
```

Opgave 2 – Inkubationstid

a.

Det givne kode kan genbruges, men med inkubationstiden sat til 14 døgn istedet for 7. Beregningen vil da vise anddelen af de smittede som forventes at udvise symptomer indenfor de 14 døgn karantæne. For at få anddelen som først vil udvise symptomer efter de 14 døgn skal den beregnede værdi trækkes fra 1. Dette vil resultere i følgende:

```r
## Hvor stor en andel af smittede vil have en inkubationstid på under 7 døgn?
inku_14 = 14
# Inkubationstid, der ønskes undersøgt
log_inku_14 = log(inku_14)
# Bemærk at i R er log() den naturlige logaritme.
# Variablen log_inku_7 = 1.9459 er den naturlige logaritme til inkubationstiden.
# Vi får at vide, at den naturlige logaritme til inkubationstiden følger en
# normalfordeling med mu = 1.6198 og standardafvigelse sigma = 0.4387
mu = 1.6198
# Middelværdi
sigma = 0.4387
# Standardafvigelse
andel_inku_under_14 = pnorm(log_inku_14, mu, sigma) # andel_inku_under_7 = 0.7714
# 77 pct af smittede vil have udvist Covid-19 symptomer efter en uge.
```

```r
andel_inku_over_14 = 1 - andel_inku_under_14

cat(andel_inku_over_14)
```

```
## 0.01007995
```

Mængden af smittede som vil udvise symptomerne efter karantænens udløb vil da være omkring 0.01 eller 1%.

b.

Medianen kan findes ved at bruge den inverse tæthedsfunktion, hvilket kan gøres i R med qnorm funktionen. Da der dog arbejdes med en log-normal-fordelingen skal svaret først indsættes i den naturlige eksponentialfunktion for at få resultatet i døgn.

```r
m = exp(qnorm(0.5, mu, sigma))
cat(m)
```

```
## 5.05208
```

Forksergruppen har ret i at medianen for inkubationstiden er omkring 5.1 døgn eller mere præcis ca. 5.052 døgn.

c.

Dette kan beregnes på samme måde, men med 95% som input i den inverse tæthedsfunktion istedet for 50% for medianen.

```r
symptom95 = exp(qnorm(0.95, mu, sigma))
cat(symptom95)
```

```
## 10.39575
```

Det forventes, at 95% af alle smittede vil have udvist symptomer efter 10.395 døgn.

d.

Det empiriske interval bestemmes som $\mu \pm 3\sigma$, hvilket svarer til:

```r
cat("[", mu-3*sigma, ",", mu+3*sigma, "]\n")
```

```
## [ 0.3037 , 2.9359 ]
```

```r
cat("eller\n")
```

```
## eller
```

```r
cat("[", exp(mu-3*sigma), ",", exp(mu+3*sigma), "], hvis det skal angives i døgn")
```

```
## [ 1.354863 , 18.83845 ], hvis det skal angives i døgn
```

Opgave 3 – Udvikling af antal døde i Danmark og Sverige

a.

Dataene justeres først som ønsket ved at fjerne de første 10 datapunkter, samt at dele antal døde med antal million indbyggere for hvert land.

```r
D = read.table("Data_ECEStat_2020_opg3.csv", header=TRUE, sep=";")

popDK = 5.8
```

```r
popSE = 10.3
start = 11
slut = length(D$Opg3_dagnummer)

X = D$Opg3_dagnummer[11:39]
YDK = D$Opg3_akkum_dk[11:39] / popDK
YSE = D$Opg3_akkum_se[11:39] / popSE

plot(X, YDK, pch = 20, col = "red", main = "Antallet af døde med Covid-19 i 2020", xlab = "Dag numre", y
points(X, YSE, pch = 20, col = "blue")
legend("topleft", legend=c("Danmark","Sverige"), fill = c("red", "blue"))
```

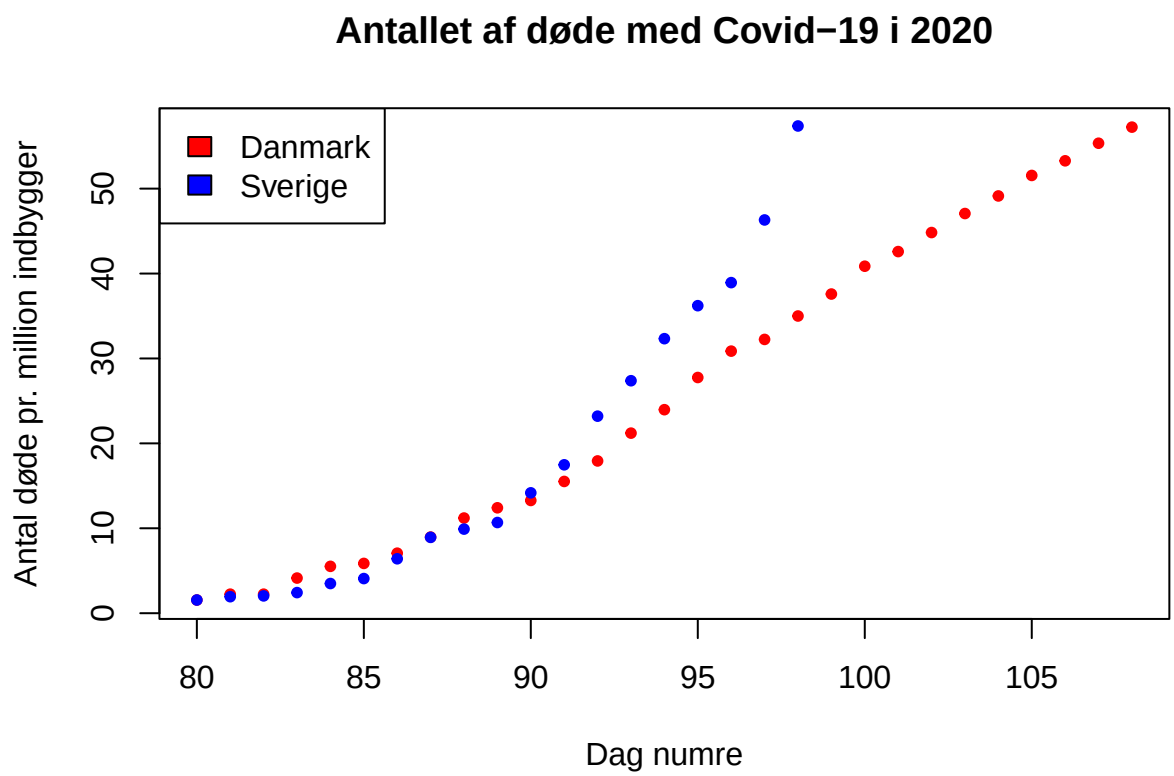

b.

Lineær regression for Danmark:

```r
DagNumre = X
lmDK = lm(YDK ~ DagNumre)
summary(lmDK)
```

```
##
## Call:
## lm(formula = YDK ~ DagNumre)
##
## Residuals:
##     Min      1Q  Median      3Q     Max
## -4.1648 -1.8774  0.5419  1.2487  5.8930
```

```
##
## Coefficients:
##               Estimate Std. Error t value Pr(>|t|)
## (Intercept) -178.59640    5.07183  -35.21   <2e-16 ***
## DagNumre       2.17819    0.05374   40.53   <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 2.421 on 27 degrees of freedom
## Multiple R-squared:  0.9838, Adjusted R-squared:  0.9832
## F-statistic:  1643 on 1 and 27 DF,  p-value: < 2.2e-16
```

Lineær regression for Sverige:

```r
lmSE = lm(YSE ~ DagNumre)
summary(lmSE)
```

```
##
## Call:
## lm(formula = YSE ~ DagNumre)
##
## Residuals:
##     Min      1Q  Median      3Q     Max
## -16.632 -12.144  -2.402   6.422  32.256
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) -412.3612    27.9054  -14.78 1.85e-14 ***
## DagNumre       4.8742     0.2957   16.48 1.28e-15 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 13.32 on 27 degrees of freedom
## Multiple R-squared:  0.9096, Adjusted R-squared:  0.9063
## F-statistic: 271.7 on 1 and 27 DF,  p-value: 1.285e-15
```

Dette resulterer i at modelligningerne for hvert land bliver følgende.

Danmark: $C(t) = 2.1782t - 178.5964$

Sverige: $C(t) = 4.8742t - 412.3612$

c.

Begge modeller passer til en rimelig grad, hvilket kan siges da begge deres p-værdier i meget tæt på 0, og de tilhørende t-værdier viser at koefficienterne er signifikant forskellig fra 0. Den danske model ser ud til at passe bedre da dens R^2 værdi er højere end den svenske. Derudover er de justerede R^2 værdier også rimelig tæt på de ikke justerede, hvilket tyder på, at der ikke er tale om en overfitted model.

En grund til, at den svenske model ikke passer lige så godt som den danske er at udviklingen ikke foregår lineært. Det kan også ses i grafen fra opgave 3.a, at den svenske graf i modsætning til den danske ser mere eksponentiel ud end lineær.

d.

```r
DK1000 = (1000 + 178.5964) / 2.1782
SE1000 = (1000 + 412.3612) / 4.8742
```

```r
cat("Danmark kan forvente at overskride 1000 døde pr. mio. indbyggere på dag", floor(DK1000), "\n")
```

```
## Danmark kan forvente at overskride 1000 døde pr. mio. indbyggere på dag 541
```

```r
cat("Sverige kan forvente at overskride 1000 døde pr. mio. indbyggere på dag", floor(SE1000))
```

```
## Sverige kan forvente at overskride 1000 døde pr. mio. indbyggere på dag 289
```

e.

Det kan ses i udledningen at lineær regression på logaritmisk data vil kunne give koefficienter svarende til hældningskoefficienten (A) og skæringen med skæring med y-aksen ($\log(B)$). Tages den naturlige eksponentialfunktion fås da den eksponentielle model.

Lineær regression for Danmark:

```r
logDK = log(YDK)
emDK = lm(logDK ~ DagNumre)
summary(emDK)
```

```
##
## Call:
## lm(formula = logDK ~ DagNumre)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.72891 -0.17007  0.06333  0.25334  0.34500
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) -8.486477   0.664818  -12.77 5.96e-13 ***
## DagNumre     0.120684   0.007045   17.13 4.96e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.3174 on 27 degrees of freedom
## Multiple R-squared:  0.9158, Adjusted R-squared:  0.9126
## F-statistic: 293.5 on 1 and 27 DF,  p-value: 4.955e-16
```

Hvor eksponentialfunktionen til $\log(B)$ giver:

```r
BDK = exp(-8.486477)
cat("B =", BDK, "\n")
```

```
## B = 0.0002062386
```

Lineær regression for Sverige:

```r
logSE = log(YSE)
emSE = lm(logSE ~ DagNumre)
summary(emSE)
```

```
##
## Call:
## lm(formula = logSE ~ DagNumre)
##
## Residuals:
##     Min      1Q  Median      3Q     Max
```

```
## -0.4408 -0.3001  0.0823  0.2395  0.3635
##
## Coefficients:
##               Estimate Std. Error t value Pr(>|t|)
## (Intercept) -12.424655   0.614915  -20.20   <2e-16 ***
## DagNumre      0.165289   0.006516   25.37   <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.2936 on 27 degrees of freedom
## Multiple R-squared:  0.9597, Adjusted R-squared:  0.9582
## F-statistic: 643.5 on 1 and 27 DF,  p-value: < 2.2e-16
```

Hvor eksponentialfunktionen til $\log(B)$ giver:

```r
BSE = exp(-12.424655)
cat("B =", BSE, "\n")
```

```
## B = 4.018286e-06
```

Dette resulterer i at modelligningerne for hvert land bliver følgende.

Danmark: $C(t) = 2.062386 \cdot 10^{-4} \cdot e^{0.120684t}$

Sverige: $C(t) = 4.018286 \cdot 10^{-6} \cdot e^{0.165289t}$

f.

Eksponentiel for Sverige pga. formen på grafen fra opgave 3.a og fordi R^2 værdien passer bedre for den ekspnoentielle model ift lineære.

Lineær for Danmark af samme grund, men omvendt da formen på grafen var lineær og den lineære model havde bedre R^2 værdi.